

[보고서]

CSIC 2010 데이터셋 규모별 로드 및 탐색 결과 비교

20242530 정명진

1. 개요

본 보고서는 CSIC 2010 HTTP 데이터셋의 기본 버전(10k)과 확장 버전(60k)을 각각 로드하여 데이터의 규모, 결측치 상황 및 주요 통계적 특성의 차이점을 분석합니다.

2. 데이터 규모 및 구조 비교

두 데이터셋 모두 동일한 18개의 컬럼으로 구성되어 있으나, 행의 수에서 약 6배의 차이를 보입니다.

항목	csic2010_requests.csv (기본)	csic2010_requests_60k.csv (확장)
전체 행 수	10,000행	61,065행
전체 열 수	18열	18열
메모리 사용량	약 1.4 MB	약 8.4 MB

3. 주요 컬럼별 데이터 분포 (결측치 및 고유값)

데이터의 크기가 커짐에 따라 각 컬럼의 Non-Null(유효 데이터) 개수와 고유값(Unique)의 수도 비례하여 증가했습니다.

- 결측치 발생 패턴: 두 파일 모두 url, accept 컬럼에서 소량의 결측치가 발견되었으며, 특히 content_type, content_length, body 컬럼은 POST 요청 등 특정 조건에서만 값이 존재하므로 대량의 결측치(NaN)가 공통적으로 나타납니다.

- 데이터 다양성: 10k 데이터셋에서 **cookie**는 10,000개의 모든 행이 고유한 값을 가졌으나, 전체적인 데이터 구조(열의 종류와 데이터 타입)는 두 파일이 완전히 동일하게 유지되고 있습니다.

4. 클래스 분포 및 기술 통계 (Classification)

정상(0)과 공격(1)을 분류하는 **classification** 컬럼의 통계치는 두 데이터셋에서 매우 유사하게 나타나, 데이터 규모가 커져도 데이터의 성향은 일정하게 유지됨을 알 수 있습니다.


통계 항목	기본 (10k)	확장 (60k)
평균 (Mean)	0.410500	0.410464
표준편차 (Std)	0.491949	0.491922
사분위수 (25%/50%/75%)	0 / 0 / 1	0 / 0 / 1

- 분석 결과: 평균값이 약 0.41로 두 데이터셋 모두 정상 데이터가 약 59%, 공격 데이터가 약 41%의 비율로 구성되어 있어 클래스 불균형이 거의 없이 일관된 분포를 보입니다.

5. 결론

csic2010_requests_60k.csv는 기본 데이터셋보다 약 6.1배 더 많은 데이터를 포함하고 있지만, 데이터의 구조, 결측치 비율, 정상/공격 데이터의 분포(약 6:4)는 거의 동일합니다. 따라서 대규모 학습이 필요한 딥러닝 모델의 경우 60k 데이터를 사용하는 것이 모델의 일반화 성능 향상에 유리할 것으로 판단됩니다.

10000개 streamlit 실행 결과



약 61000개 streamlit 실행 결과

